

Nombre: Emiliano Mayo Hernández		Matrícula: 3063467
Diego Nuñez MARTINEZ		2942419
Ángel Gabriel Zamora Vázquez		3069241
Nombre del curso:	Nombre del profesor:	
Proyectos de ingeniería de software	Gino Gerardo Madrazo Galvez	
Módulo:	Actividad: Fase 4	
3		
Fecha: 30/Abril/2026		

Índice:

Actividad 11. Índice de documentos	1
Actividad 12. Buscar en el diccionario	4
Actividad 13. Búsquedas optimizadas en el diccionario.....	13

Actividad 11. Índice de documentos

Desarrollo de la actividad

En esta actividad estás entrando a la cuarta fase del proyecto: query. Aquí crearás las funciones necesarias para hacer las consultas al diccionario; se divide en tres acciones.

En esta actividad crearás un archivo de documentos que contenga una relación entre el posting file y el nuevo archivo de documentos. Básicamente, lo que harás es darle un ID único a cada documento y almacenar su nombre (o el path completo con nombre).

Crear historias de usuario

1. Tú y tu equipo scrum creen las historias de usuario necesarias para este sprint.
2. Refinen y asignen puntos a cada historia de usuario.

Planeación del Sprint

Fase: 4 (Query)

Objetivo del Sprint: Desacoplar los nombres de los archivos del archivo Posting, creando un catálogo de documentos indexados por ID y calculando el peso TF-IDF de cada coincidencia.

Historias de Usuario

Actividad 11

Primera Historia. Archivo Documentos

- o Como Product Owner,
- o Quiero que el sistema genere un catálogo (documentos.txt) que asocie un ID numérico único secuencial con el nombre original de cada archivo HTML,
- o Para asegurar la normalización de los datos, optimizar el almacenamiento del proyecto y facilitar la gestión de los archivos indexados.

Segunda Historia. Posting con TF-IDF


- o Como Desarrollador,
- o Quiero modificar el código que genera el archivo posting.txt para que reemplace el nombre del archivo por su ID numérico, y agregue el peso de cada token calculado con la fórmula TF-IDF,
- o Para reducir el consumo de memoria RAM y construir la base matemática necesaria para buscar palabras por relevancia.

Tercera Historia. Log de Tiempos

- o Como Scrum Master,
- o Quiero que el programa exporte automáticamente un archivo de texto (a11_matricula.txt) con los tiempos de ejecución de cada documento procesado y el tiempo total del proceso,
- o Para monitorear la eficiencia del algoritmo, auditar el rendimiento del equipo durante este sprint y detectar posibles cuellos de botella.

Crear archivo de documentos

3. Creen un tercer archivo de documentos que relacione el nombre y path del documento con ID único para que sea almacenado de esa manera en el posting file, por ejemplo:



4. Modifiquen el archivo posting para que incluya el documentID y peso de cada token. Haz clic [aquí](#) para desplegar un ejemplo de cómo quedarían los archivos de posting, documentos y diccionario.


Medición de tiempos

5. Agreguen un archivo log de salida con nombre **a11_matricula.txt**.
6. Cronometren el tiempo que tarda tu programa en procesar cada archivo y lo que tarda en todo el proceso.
7. Incluye el archivo log de salida.

Resultados de la Actividad:

Se generó exitosamente el catálogo documentos.txt. Al reemplazar los nombres completos de los archivos por IDs numéricos secuenciales, logramos reducir drásticamente el peso de las estructuras y el consumo de memoria RAM.

El archivo posting.txt evolucionó; ahora no solo registra dónde aparecen las palabras, sino que calcula su peso e importancia matemática (TF-IDF) basándose en la longitud total de cada documento.



Se integró un sistema de cronometraje de alta precisión en C++ que genera automáticamente el log de tiempos (a11_matricula.txt).

Actividad 12. Buscar en el diccionario

Historias de usuario

1. Búsqueda de una palabra

Como Usuario, quiero ingresar una palabra en el programa, para obtener la lista de documentos donde aparece.

2. Consulta desde terminal


Como Usuario, quiero ejecutar el programa desde la terminal con un comando (retrieve palabra), para facilitar el acceso y uso del sistema.

3. Registro de tiempos de búsqueda

Como Scrum Master, quiero que el sistema genere un archivo de log (a12_matricula.txt) con el tiempo de cada búsqueda, para medir el rendimiento del programa.

Creen un nuevo programa para que reciba una palabra. Creen otro juego de archivos de diccionario, posting y documentos, pero esta vez sin aplicar el filtro stop list

El programa será llamado en un comando DOS/Unix/Linux. Por ejemplo, **retrieve gato**.



- diccionario.txt
- diccionario_sin_stop.txt
- documentos.txt
- documentos_sin_stop.txt
- posting.txt
- posting_sin_stop.txt

```
Ingresa el comando: retrieve lawyer consumers
Deseas usar stop list? (s/n): s
```

```
Comando confirmado: retrieve lawyer
Version seleccionada: CON stop list
Archivos usados:
- diccionario.txt
- posting.txt
- documentos.txt
```

El programa imprimirá la lista de todos los documentos que contengan la palabra que se busca. Por ejemplo, si escriben gato como entrada, regresará algo como lo siguiente:

```
1. 004.html
2. 231.html
..
..
N. n.html
```

```
Documentos encontrados:
1. 009.html
2. 011.html
```

? Realicen la búsqueda de los siguientes tokens:

a. Gauch

```
Ingresa el comando: retrieve Gauch
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve gauch
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 002.html
2. 004.html
```

b. elephants

```
Comando confirmado: retrieve elephants
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 006.html
```

c. CSCE

```
Ingresa el comando: retrieve CSCE
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve csce
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 008.html
2. 003.html
```

d. Arkansas

```
Ingresa el comando: retrieve Arkansas
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve arkansas
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 005.html
```

e. gift

```
Ingresa el comando: retrieve gift
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve gift
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 007.html
2. 009.html
```

f. abcdef

```
Ingresa el comando: retrieve abcdef
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve abcdef
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
```


g. 20

```
Ingresa el comando: retrieve 20
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve 20
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 010.html
2. 011.html
```

h. 20.07

```
Ingresa el comando: retrieve 20.07
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve 20.07
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 002.html
```

i. 123-456-7890

```
Ingresa el comando: retrieve 123-456-7890
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve 123-456-7890
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 003.html
```

j. lawyer consumers

```
Ingresa el comando: retrieve lawyer consumers
Deseas usar stop list? (s/n): n

Comando confirmado: retrieve lawyer
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 005.html
2. 007.html

Comando confirmado: retrieve consumers
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

Documentos encontrados:
1. 009.html
2. 011.html
```

k. garden computer

```
Ingresa el comando: retrieve garden computer
Deseas usar stop list? (s/n): n
```

```
Comando confirmado: retrieve garden
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt
```

```
Documentos encontrados:
1. 003.html
```

```
Comando confirmado: retrieve computer
Version seleccionada: SIN stop list
Archivos usados:
- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt
```

```
Documentos encontrados:
1. 004.html
2. 006.html
```

l. United States laws

```
Ingresa el comando: retrieve United States laws  
Deseas usar stop list? (s/n): n
```

```
Comando confirmado: retrieve united  
Version seleccionada: SIN stop list
```

```
Archivos usados:
```

- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

```
Documentos encontrados:
```

1. 008.html
2. 003.html

```
Comando confirmado: retrieve states  
Version seleccionada: SIN stop list
```

```
Archivos usados:
```

- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

```
Documentos encontrados:
```

1. 005.html
2. 007.html

```
Comando confirmado: retrieve laws  
Version seleccionada: SIN stop list
```

```
Archivos usados:
```

- diccionario_sin_stop.txt
- posting_sin_stop.txt
- documentos_sin_stop.txt

```
Documentos encontrados:
```

1. 009.html
2. 010.html

Agreguen un archivo log de salida con el nombre **a12_matricula.txt**.

```
a12_matricula.txt
Archivo  Editar  Ver  H1  ⌵  ≡
Tiempo: 0.0009072 segundos
=====
Consulta: 20
Modo: SIN stop list
Tiempo: 0.0019375 segundos
=====
Consulta: 20.07
Modo: SIN stop list
Tiempo: 0.0013883 segundos
=====
Consulta: 123-456-7890
Modo: SIN stop list
Tiempo: 0.0013443 segundos
=====
Consulta: lawyer consumers
Modo: SIN stop list
Tiempo: 0.0031398 segundos
=====
Consulta: garden computer
Modo: SIN stop list
Tiempo: 0.0025779 segundos
=====
Consulta: United States laws
Modo: SIN stop list
Tiempo: 0.0077556 segundos
=====
```

Conclusión: desarrollamos un programa capaz de buscar palabras dentro del diccionario y recuperar los documentos asociados. Se implementó la ejecución desde terminal, el manejo de tokens y el registro de tiempos de búsqueda, logrando una funcionalidad básica de consulta que sirve como base para optimizaciones posteriores.

Actividad 13. Búsquedas optimizadas en el diccionario

- **Historias de usuario actividad 13**

1. Búsqueda optimizada sin memoria

Como el desarrollador, quiero que el sistema busque palabras leyendo desde los archivos en disco sin cargar todo en memoria, para que no afecte tanto el rendimiento y reducir el uso del sistema.

2. Búsqueda de múltiples tokens

Como un usuario, quiero ingresar varias palabras en una sola consulta, como ejemplo: gauch, elephant, 20, etc.

3. Ranking de resultados (Top 10)

Como un usuario, quiero que el sistema me arroje los 10 documentos más relevantes, para así identificar rápido la información.

4. Consulta desde terminal

Como un usuario, quiero ejecutar el programa desde la terminal con comandos simples retrieve + palabra, para que facilite el sistema a mi como usuario.

5. Log de tiempos de búsqueda

Como scrum máster, quiero que el sistema registre en un archivo (a13_3069241.txt) y que registre el tiempo de cada búsqueda hecha para evaluar el rendimiento del nuestro sistema.

- El programa será llamado en un comando DOS/Unix/Linux y debe aceptar varios tokens de entrada.
- El programa imprimirá la lista de todos los documentos que contengan las palabras que se desea busca.

Se realizó la búsqueda de los siguientes tokens:

- a. Gauch
- b. elephants
- c. CSCE
- d. Arkansas
- e. gift

- f. abcdef
- g. 20
- h. 20.07
- i. 123-456-7890
- j. lawyer consumers
- k. garden computer
- l. United States laws

```
101 102 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160 161 162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179 180 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197 198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215 216 217 218 219 220 221 222 223 224 225 226 227 228 229 230 231 232 233 234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 250 251 252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268 269 270 271 272 273 274 275 276 277 278 279 280 281 282 283 284 285 286 287 288 289 290 291 292 293 294 295 296 297 298 299 300 301 302 303 304 305 306 307 308 309 310 311 312 313 314 315 316 317 318 319 320 321 322 323 324 325 326 327 328 329 330 331 332 333 334 335 336 337 338 339 340 341 342 343 344 345 346 347 348 349 350 351 352 353 354 355 356 357 358 359 360 361 362 363 364 365 366 367 368 369 370 371 372 373 374 375 376 377 378 379 380 381 382 383 384 385 386 387 388 389 390 391 392 393 394 395 396 397 398 399 400 401 402 403 404 405 406 407 408 409 410 411 412 413 414 415 416 417 418 419 420 421 422 423 424 425 426 427 428 429 430 431 432 433 434 435 436 437 438 439 440 441 442 443 444 445 446 447 448 449 450 451 452 453 454 455 456 457 458 459 460 461 462 463 464 465 466 467 468 469 470 471 472 473 474 475 476 477 478 479 480 481 482 483 484 485 486 487 488 489 490 491 492 493 494 495 496 497 498 499 500 501 502 503 504 505 506 507 508 509 510 511 512 513 514 515 516 517 518 519 520 521 522 523 524 525 526 527 528 529 530 531 532 533 534 535 536 537 538 539 540 541 542 543 544 545 546 547 548 549 550 551 552 553 554 555 556 557 558 559 560 561 562 563 564 565 566 567 568 569 570 571 572 573 574 575 576 577 578 579 580 581 582 583 584 585 586 587 588 589 590 591 592 593 594 595 596 597 598 599 600 601 602 603 604 605 606 607 608 609 610 611 612 613 614 615 616 617 618 619 620 621 622 623 624 625 626 627 628 629 630 631 632 633 634 635 636 637 638 639 640 641 642 643 644 645 646 647 648 649 650 651 652 653 654 655 656 657 658 659 660 661 662 663 664 665 666 667 668 669 670 671 672 673 674 675 676 677 678 679 680 681 682 683 684 685 686 687 688 689 690 691 692 693 694 695 696 697 698 699 700 701 702 703 704 705 706 707 708 709 710 711 712 713 714 715 716 717 718 719 720 721 722 723 724 725 726 727 728 729 730 731 732 733 734 735 736 737 738 739 740 741 742 743 744 745 746 747 748 749 750 751 752 753 754 755 756 757 758 759 760 761 762 763 764 765 766 767 768 769 770 771 772 773 774 775 776 777 778 779 780 781 782 783 784 785 786 787 788 789 790 791 792 793 794 795 796 797 798 799 800 801 802 803 804 805 806 807 808 809 810 811 812 813 814 815 816 817 818 819 820 821 822 823 824 825 826 827 828 829 830 831 832 833 834 835 836 837 838 839 840 841 842 843 844 845 846 847 848 849 850 851 852 853 854 855 856 857 858 859 860 861 862 863 864 865 866 867 868 869 870 871 872 873 874 875 876 877 878 879 880 881 882 883 884 885 886 887 888 889 890 891 892 893 894 895 896 897 898 899 900 901 902 903 904 905 906 907 908 909 910 911 912 913 914 915 916 917 918 919 920 921 922 923 924 925 926 927 928 929 930 931 932 933 934 935 936 937 938 939 940 941 942 943 944 945 946 947 948 949 950 951 952 953 954 955 956 957 958 959 960 961 962 963 964 965 966 967 968 969 970 971 972 973 974 975 976 977 978 979 980 981 982 983 984 985 986 987 988 989 990 991 992 993 994 995 996 997 998 999 1000
```

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS CODE REFERENCE LOG

PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe gauch
Top documents:
1. hard.html
2. simple.html
3. consolidado_alfabetico.html
4. consolidado_frecuencia.html

Tiempo: 0.0639498 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe elephants
Top documents:
1. medium.html

Tiempo: 0.0583716 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe CSCE
Top documents:
1. medium.html
2. consolidado_alfabetico.html
3. consolidado_frecuencia.html

Tiempo: 0.273485 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe Arkansas
Top documents:
1. 399.html
2. 411.html
3. 430.html
4. 400.html
5. 406.html
6. 413.html
7. 402.html
8. 404.html
9. 422.html
10. 409.html

Tiempo: 0.279345 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe gift
Top documents:
1. 149.html
2. 324.html
3. 180.html
4. 051.html
5. 397.html
6. 074.html
7. 026.html
8. 383.html
9. 298.html
10. 043.html
```

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS  CODE REFERENCE LOG

PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe abcdef
Top documents:

Tiempo: 0.360959 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe 20
Top documents:
1. medium.html
2. 412.html
3. 399.html
4. 429.html
5. 413.html
6. 494.html
7. 432.html
8. 113.html
9. 431.html
10. 398.html

Tiempo: 0.016373 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe 20.07
Top documents:

Tiempo: 0.36589 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe 123-456-7890
Top documents:

Tiempo: 0.358548 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe lawyer consumers
Top documents:
1. 386.html
2. 395.html
3. 087.html
4. 154.html
5. 129.html
6. 136.html
7. 445.html
8. 230.html
9. 207.html
10. 091.html

Tiempo: 0.624508 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe garden computer
Top documents:
1. 060.html
2. 502.html
3. 380.html
4. 499.html
5. 038.html

Java: Ready
```

```
Tiempo: 0.327344 segundos
PS C:\Users\shark\Downloads\Fase_4> actividad_13/retrieve.exe united states laws
Top documents:
1. 384.html
2. 113.html
3. 159.html
4. 092.html
5. 175.html
6. 157.html
7. 184.html
8. 121.html
9. 197.html
10. 232.html

Tiempo: 0.819174 segundos
PS C:\Users\shark\Downloads\Fase_4> █
```


- Agreguen un archivo log de salida con nombre `a13_matricula.txt`, en donde se vayan almacenando las búsquedas realizadas, así como los tiempos en cada búsqueda.

```

1 Consulta: gauch | Tiempo: 0.0625723 s
2 Consulta: gauch | Tiempo: 0.0629339 s
3 Consulta: elephants | Tiempo: 0.058488 s
4 Consulta: csce | Tiempo: 0.293681 s
5 Consulta: arkansas | Tiempo: 0.279372 s
6 Consulta: gift | Tiempo: 0.28541 s
7 Consulta: abcdef | Tiempo: 0.361473 s
8 Consulta: 20 | Tiempo: 0.0177996 s
9 Consulta: 20.07 | Tiempo: 0.358533 s
10 Consulta: 123-456-7890 | Tiempo: 0.357895 s
11 Consulta: lawyer consumers | Tiempo: 0.615348 s
12 Consulta: garden computer | Tiempo: 0.327476 s
13 Consulta: united states laws | Tiempo: 0.833215 s
14

```

- Cronometren el tiempo que tarda tu programa en hacer una búsqueda.

Consulta	Tiempo (s)
gauch	0.0627531
elephants	0.058488
csce	0.293681
arkansas	0.279372
gift	0.28541
abcdef	0.361473
20	0.017996
20.07	0.358533
123-456-7890	0.357895

lawyer consumers	0.615348
garden computer	0.327476
united states laws	0.830844

Conclusión:

Este programa me permitió implementar un sistema de búsqueda optimizado que procesa consultas directamente desde archivos en disco, sin cargar estructuras completas.

Se logró manejar múltiples tokens, calcular relevancia y mostrar el top 10 de resultados, además de registrar cada uno de los tiempos, para que mejore la eficiencia, su rendimiento y funcionalidad del motor de búsqueda.